

PRÁCTICA 4: DETECCIÓN DE NEUMONÍA EN BASE A RAYOS-X



SISTEMAS INTELIGENTES

CURSO 2023-2024

AUTORES

ANDRÉS VIÑÉ SÁNCHEZ, BEATRIZ AEDO DÍAZ, CANDELA
ESQUINAS SÁNCHEZ, JOSÉ ANTONIO RUIZ HEREDIA

GRADO EN INGENIERÍA INFORMÁTICA

FACULTAD DE INFORMÁTICA

UNIVERSIDAD COMPLUTENSE DE MADRID

RESUMEN

Título

Dentro del campo de la Inteligencia Artificial, la clasificación de imágenes es una parte muy desarrollada y relevante.

Durante los fatídicos años que el mundo sufrió de la enfermedad del coronavirus, la sanidad se vio afectada en todo momento. Se encontraron con una situación completamente desbordada que fue difícil de mantener bajo control. Por ello en este proyecto se ha decidido tratar con la clasificación de imágenes de Rayos - X de torsos con y sin neumonía, que es una de las variantes que generan los desagradables síntomas del COVID - 19.

Tras realizar un proceso de preprocesamiento, este estudio emplea el modelo pre entrenado, ResNet50V2, basado en una arquitectura de Redes Convolucionales, cuyos resultados han sido analizados posteriormente tratando de buscar los más óptimos posibles. La implementación del modelo se lleva a cabo mediante las librerías más relevantes de Python en este área, como son Pytorch, Keras y Tensorflow. Para realizar el preprocesamiento y posteriormente la clasificación, se emplea un dataset que contiene radiografías de distintos torsos, con y sin neumonía.

Palabras clave

Inteligencia Artificial, Neumonía, Rayos-X, ResNet50V2, Preprocesamiento, Modelo, Resultados

ÍNDICE DE CONTENIDOS

Capítulo 1 - Introducción.....	7
1.1 Motivación.....	7
1.2 Objetivos.....	8
1.3. Plan de trabajo.....	9
Capítulo 2 - Primeros Pasos.....	10
2.1. Elección del Dataset.....	10
2.2. Carga de Datos.....	10
Capítulo 3 - Preprocesamiento y Edición de las Imágenes.....	12
3.1. Importación de Librerías y Carga de Datos del CSV.....	12
3.2. Primera Etapa del Pre-procesado de los Datos.....	13
3.3. Segunda Etapa del Preprocesado de Datos.....	16
Capítulo 4 - Modelo.....	18
4.1. Introducción.....	18
4.2. Redes Neuronales Convolucionales (CNN).....	18
4.2.1. Inspiración Biológica De Las Redes Neuronales.....	19
4.2.2. Convolución.....	19
4.3. ResNet50V2.....	21
4.4. Procesamiento Imágenes De Las Radiografías.....	22
Capítulo 5 - Resultados.....	23
5.1. Sin Preprocesamiento.....	23
5.2. Primer preprocesamiento.....	26
Capítulo 6 - Conclusiones y trabajo futuro.....	33
ANEXO - Tareas realizadas por miembro.....	37

ÍNDICE DE FIGURAS

Figura 3-1. Cantidad de datos por categoría y tipo.....	12
Figura 3-2. Gráficos de cantidad de datos por categoría y tipo.....	13
Figura 3-3. Imágenes con diferentes tamaños.....	14
Figura 3-4. Imágenes con diferentes niveles de suavizado.....	14
Figura 3-5. Imágenes con diferentes niveles de contraste.....	14
Figura 3-6. Imágenes con diferentes niveles de Grid.....	15
Figura 3-7. Comparación de imágenes de categoría Normal.....	15
Figura 3-8. Comparación de imágenes de categoría Neumonía.....	16
Figura 3-9. Imágenes con diferentes niveles de umbral.....	16
Figura 3-10. Comparación de imágenes normales con filtro y umbral.....	17
Figura 3-11. Comparación de imágenes con Neumonía con filtro y umbral.....	17
Figura 4-1. Detección de caras mediante redes neuronales.....	19
Figura 4-2. Ejemplos de filtros.....	20
Figura 4-3. Diagrama de una CNN meramente explicativo.....	20
Figura 4-4. Diagrama del Modelo ResNetV2.....	21
Figura 4-5. Skip connection.....	22
Figura 4-6. Esquema de entrenamiento del modelo.....	22
Figura 5-1. Métricas.....	23
Figura 5-2. Resultados de la evaluación de las imágenes.....	24
Figura 5-3. Resultados de los falsos positivos de las imágenes.....	24
Figura 5-4. Resultados de los falsos positivosde las imágenes.....	24
Figura 5-5. Matriz de confusión.....	25
Figura 5-6. Ejemplos falsos positivos.....	25
Figura 5-7. Entrenamiento vs. Validación.....	26
Figura 5-8. Métricas.....	27
Figura 5-9. Matriz de confusión.....	27
Figura 5-10. Entrenamiento vs. Validación.....	27
Figura 5-11. Aumentos de datos.....	28
Figura 5-12. Métricas.....	28
Figura 5-13. Resultados de la evaluación de las imágenes.....	29
Figura 5-14. Matriz de confusión.....	29
Figura 5-15. Ejemplos falsos positivos.....	30
Figura 5-16. Conjunto de imágenes 'normales'	30
Figura 5-17. Entrenamiento vs. Validación.....	31

Figura 5-18. Matriz de confusión.....	32
Figura 5-19. Métricas.....	32
Figura 5-20. Entrenamiento vs. Validación.....	32

ÍNDICE DE TABLAS

Tabla 1. Trabajo realizado por cada miembro.....	24
--	----

Capítulo 1 - Introducción

La inteligencia artificial es un término que desde hace unos años se encuentra en plena efervescencia. Es un campo de la informática que busca crear sistemas y programas capaces de dotar a una máquina de habilidades humanas, como el aprendizaje. Su aplicación en diversos ámbitos la dotan continuamente de más y más importancia, y es que su versatilidad de uso permite que se pueda aplicar en cada vez más sectores como en la medicina se ha convertido en un soporte a la hora de tomar decisiones clínicas sobre tratamientos, medicamentos y otras necesidades del paciente o en la economía donde los análisis de datos y predicción contribuyen a la detección de fraudes. Por no añadir los asistentes virtuales, que han tomado protagonismo en los hogares, y están siendo integrados en una amplia gama de dispositivos, desde teléfonos hasta coches.

La inteligencia artificial, definitivamente, ha revolucionado nuestras vidas, sin embargo, debido al desconocimiento, aún se ve en ocasiones como un enemigo, y entre los pensamientos más comunes se encuentra el que predice que nos acabará sustituyendo en ciertos puestos de trabajo.

Este trabajo quiere mostrar lo contrario, que la inteligencia artificial es nuestro aliado y que las máquinas pueden ayudarnos, concretamente en nuestro caso, a salvar vidas.

1.1 Motivación

La COVID - 19 es una enfermedad infecciosa internacional que nos amenaza desde finales de 2019. Originaria de China, se extendió con facilidad por todo el continente asiático hasta terminar contagiando al mundo entero de manera masiva y con unos síntomas variables. Lejos de ser un constipado común, abarcaba neumonías, síndromes respiratorios, además de los síntomas gripales que todos conocíamos, o que creíamos conocer, ya que, uno de los múltiples inconvenientes

de esta enfermedad es la versatilidad de desarrollo en el cuerpo que habita, puesto que no operaba en el cuerpo humano con un patrón fijo. El coronavirus acabó con 4.5 millones de vidas e infectó a unas 219 millones de personas.

A nivel mundial, se declaró estado de emergencia sanitaria el 11 de marzo de 2020. El 15 de marzo de 2020, la población española dejó de tener libertad para salir de sus casas, comenzando así un periodo de cuarentena que no cesó hasta junio de ese mismo año.

Durante los meses de emergencia sanitaria, los servicios sanitarios colapsaron de manera drástica por la alta demanda de los mismos. Con todos los hospitales colapsados y los enfermos en condiciones precarias, la sanidad se vio acorralada.

Por ello, este proyecto se visualizó con la esperanza de poder facilitar el trabajo a aquellos médicos, enfermeros o auxiliares que dieron la vida por los enfermos de coronavirus.

1.2 Objetivos

Existen numerosos síntomas del COVID - 19 para los cuales una detección temprana es crucial y que resultan atractivos de investigar mediante la Inteligencia artificial. Nos centraremos en las afecciones respiratorias, concretamente la neumonía, la cual en pacientes con otro tipo de problemas respiratorios, puede convertirse en un síntoma de alto riesgo.

En este proyecto, realizaremos la creación exhaustiva de un modelo que nos permita, en base a imágenes de Rayos-X de la zona torácica de los pacientes, detectar si los enfermos padecen neumonía.

Además se pretende profundizar y estudiar los conceptos teóricos de las redes neuronales que se van a implementar.

El enfoque principal será conseguir una clasificación de imágenes, en las cuales se presentarán Rayos-X donde se observarán pulmones afectados por la neumonía, y pulmones sanos.

1.3. Plan de trabajo

A continuación se presenta la arquitectura de la memoria, con un breve resumen de los puntos a tratar:

- Capítulo 1 - Introducción: En este primer capítulo se realiza una visión general de los objetivos y la motivación del proyecto.
- Capítulo 2 - Primeros Pasos: En el segundo capítulo se presentan el conjunto de datos que van a ser preprocesados y usados para el correcto funcionamiento de la red neuronal y la carga de datos.
- Capítulo 3 - Preprocesamiento y edición de las imágenes: El tercer capítulo se centra en la explicación del preprocesamiento de los datos. Se acompaña de una explicación sobre las herramientas requeridas, los pasos a seguir, las librerías utilizadas, etc.
- Capítulo 4 - Modelo: El capítulo cuatro muestra el modelo que resulta más adecuado mediante una justificación analítica, para resolver el problema planteado.
- Capítulo 5 - Resultados. Este capítulo se centra en la presentación de los resultados tras el entrenamiento del modelo.
- Capítulo 6 - Conclusión y futuros trabajos: En este sexto capítulo se sintetizan las conclusiones y se recapitulan los aspectos más importantes expuestos en el documento. Finalmente se plantean futuros trabajos orientados a mejorar el método utilizado, o relacionados con ello.

Capítulo 2 - Primeros Pasos

2.1. Elección del Dataset

Una vez la temática de este proyecto es elegida, se necesita encontrar en internet un dataset. En este caso se ha utilizado un dataset de imágenes de Rayos-X, encontrado en Kaggle. En la misma página web también se encontró una guía de cómo crear el modelo.

- Dataset:

<https://www.kaggle.com/datasets/paultimothymooney/chest-xray-pneumonia/data>

- Guía:

<https://www.kaggle.com/code/gokifujiya/pneumonia-in-chest-x-ray-resnet50-v2-94-or-88-acc>

2.2. Carga de Datos

Antes de empezar a procesar las imágenes o cargar el modelo, es esencial cargar los datos que serán utilizados por el programa y clasificarlos correctamente. Para ello, creamos un programa "Label_Dataset.ipynb" y a continuación se explica más en detalle lo que hace dicho programa.

En primer lugar, se definen las etiquetas y columnas que tendrá el CSV. Siendo las etiquetas de categorías "Normal" y "Pneumonia" y las de los tipos de datos "Train", "Test" y "Val". Las columnas del CSV, siendo cada fila una imagen, serán la ruta a dicha imagen, su nombre, el índice y la etiqueta de la categoría y el índice y la etiqueta del tipo de dato. Lo siguiente es comenzar a preparar el CSV para cargar los datos, para ello se definen métodos que devuelvan la categoría o el tipo de dato en base a el índice de estos y, además, se escribe en la primera fila del CSV los títulos que van a tener cada columna, que ya han sido mencionados anteriormente.

En este momento, ya se puede empezar a cargar los datos a el CSV, por lo que el siguiente paso es comenzar a recorrer la ruta dónde están almacenadas las imágenes por tipo de dato y categoría, en ese orden ya que es así cómo están almacenados, y cargar los datos en el CSV.

Una vez este último paso está completado, los datos ya están cargados y se puede comenzar con el preprocesamiento de las imágenes.

Capítulo 3 - Preprocesamiento y Edición de las Imágenes

Para poder realizar estos siguientes pasos se ha creado un script nuevo, llamado "Data_Preprocessing_and_Augmentation.ipynb", siendo el nombre descriptivo de lo que realiza este programa.

3.1. Importación de Librerías y Carga de Datos del CSV

Como se ha mencionado anteriormente, el dataset utilizado en este proyecto es uno encontrado en Kaggle, por lo que antes de comenzar a procesar las imágenes es importante saber cuántos tipos de datos tenemos de cada categoría o tipo, y así poder asegurar que la cantidad de datos cada tipo o categoría está equiparada.

En primer lugar, son cargadas las librerías que van a ser utilizadas. Siendo estas las librerías de TensorFlow, sklearn, numpy y pandas, entre otras. Una vez este paso ya ha sido realizado, se cargan los datos por categoría y tipo. A su vez, creando dos diccionarios, uno que almacene el número de datos que hay de cada categoría y otro que almacene el número de datos que hay de cada tipo. Para poder visualizar bien cuántos datos hay de cada se imprimen en pantalla.

```
Cantidad de datos por categoría:  
Normal: 1583  
Pneumonia: 4273  
  
Cantidad de datos por tipo:  
Train: 5216  
Test: 624  
Val: 16
```

Figura 3-1. Cantidad de datos por categoría y tipo.

Se puede observar un desequilibrio en el tamaño de las imágenes de neumonía respecto a las normales. Este desequilibrio puede afectar el rendimiento

del modelo. Para poder observar mejor las diferencias entre la cantidad de datos por categoría y tipo, se crean dos gráficos.




Figura 3-2. Gráficos de cantidad de datos por categoría y tipo.

Por último, se cargan todas las rutas de las imágenes en dos dataframes, "Pneumonia" y "Normal".

3.2. Primera Etapa del Pre-procesado de los Datos

Este paso es relativamente importante, no solo para el rendimiento sino también para la precisión que posteriormente tenga el modelo. Por ello muchas veces requiere que se prueben diferentes escenarios de tamaño de imagen, contraste, etcétera. Para ello, se crean dos funciones diferentes, una que ajusta el tamaño de imagen según unos parámetros que se indican al llamar a la función, y otra que ajusta los niveles de grises, suavizado y contraste de las imágenes. Posteriormente, va a ser necesario tener en cuenta que el tamaño de imagen tiene que poder ser admitido por el modelo elegido. Primero se prueban diferentes tamaños en una de las imágenes y se muestran para poder elegir el que se considere que va a ser mejor. Al final, se ha elegido que tenga un tamaño de 220x220.




Figura 3-3. Imágenes con diferentes tamaños.

A continuación, se realiza la misma prueba que antes pero con diferentes niveles de suavizado.




Figura 3-4. Imágenes con diferentes niveles de suavizado.

Lo siguiente es estudiar cómo afectan diferentes niveles de contraste a una imagen.



Figura 3-5. Imágenes con diferentes niveles de contraste.

Se estudia cómo afecta el tamaño de los bloques en los que se divide la imagen para calcular la ecualización. A lo que se denominará como "grid". Un tamaño de bloque más grande puede suavizar el efecto de la ecualización del histograma, mientras que un tamaño de bloque más pequeño puede capturar mejor las variaciones locales en el contraste.




Figura 3-6. Imágenes con diferentes niveles de Grid.

A continuación, se observan las imágenes con el filtro aplicado en comparación con las originales. Se cogen aleatoriamente dos imágenes normales y dos con neumonía y se les aplican un tamaño de grid 8, contraste de 2.5 y suavizado o blur 1.




Figura 3-7. Comparación de imágenes de categoría Normal.




Figura 3-8. Comparación de imágenes de categoría Neumonía.

La siguiente prueba realizada es el estudio de la aplicación de un “umbral” o “threshold” para convertir la imagen en solo blancos y negros. Esto se realiza con el objetivo de resaltar las zonas de interés.




Figura 3-9. Imágenes con diferentes niveles de umbral.

3.3. Segunda Etapa del Preprocesado de Datos

La segunda etapa del preprocesado de los datos comienza con la realización de una prueba con todos los filtros que se han mencionado anteriormente y el umbral de 120, comparándolo con sus versiones originales.

Eligiendo de forma aleatoria dos imágenes normales y dos con neumonía. Esta prueba es la última que se realiza en el preprocesado de los datos.




Figura 3-10. Comparación de imágenes normales con filtro y umbral.




Figura 3-11. Comparación de imágenes con Neumonía con filtro y umbral.

Capítulo 4 - Modelo

4.1. Introducción

Este estudio emplea el modelo pre entrenado ResNet50V2 basado en Deep Learning para clasificar radiografías del torso en dos categorías: Neumonía y Normal.

Al ser una tarea compleja y requerir de mucha potencia de cálculo para entrenar un modelo de reconocimiento de imágenes desde cero, hemos decidido utilizar este modelo (ResNet50V2), el cual es uno de los más utilizados en el campo de la visión por computador. De esta manera tan solo ha sido necesario reentrenar las últimas capas de la red neuronal para ajustarlo a nuestro objetivo.

El modelo está basado en una arquitectura de Redes Neuronales Convolucionales, CNN por sus siglas en inglés (Convolutional Neural Network).

4.2. Redes Neuronales Convolucionales (CNN)

La arquitectura de CNN es ideal a la hora de analizar y reconocer imágenes. Ha sido una de las mayores revoluciones en visión por computador y se utiliza tanto para clasificación como detección, segmentación, reconocimiento facial... Aunque en el caso de este estudio, nos limitaremos a utilizar esta arquitectura para la clasificación en dos categorías de imágenes.

Las CNN funcionan bastante mejor que las Redes Neuronales tradicionales a la hora de reconocer patrones visuales al ser capaces de interpretar mejor las relaciones espaciales y las diferencias entre los píxeles.

Para entender bien cómo funciona el modelo ResNet50V2, es necesario tener una intuición sobre cómo funcionan las CNN.

4.2.1. Inspiración Biológica De Las Redes Neuronales

Proceso de visión humano: reconocimiento de imágenes basados en puntos de interés. Reconocemos imágenes a través de la aparición de elementos que nos indican que un objeto es el que es. Para ello tenemos necesariamente que reconocer cada uno de los elementos individuales del objeto a clasificar para lo cual nos valemos del mismo mecanismo. Esto se denomina procesamiento en cascada (primero se detectan los elementos básicos y generales, y luego estos se combinan para formar patrones más complejos).

Un ejemplo es la detección de caras a través de la presencia de unos ojos, una nariz y una boca. Los ojos se reconocen a través de la presencia del iris, la pupila, las pestañas, etc y estos a su vez a través de la detección de patrones circulares de color negro (pupila), zonas blancas (esclerótica), patrones contrastados de líneas (pestañas), etcétera.




Figura 4-1. Detección de caras mediante redes neuronales

4.2.2. Convolución

Operación matemática que permite recalcular el valor de cada píxel de la imagen. Utilizando una matriz o filtro con diferentes valores y utilizando los píxeles adyacentes se calculará una suma ponderada de los mismos, otorgando dicho valor al píxel objetivo. En función del filtro que aplicamos obtendremos diferentes imágenes como output de la operación de convolución. Algunos ejemplos de filtros son los siguientes.





Figura 4-2. Ejemplos de filtros

Las CNN procesan una imagen, aplicando diferentes filtros y generando una serie de mapas de características. La potencia de estas redes basadas en la idea de procesamiento en cascada: El output de cada una de las capas, servirá como input para la entrada siguiente. A cada capa que aplicamos la operación de convolución cada vez es más potente. Debido a la sucesión de convoluciones, en cada pixel de la imagen cada vez tendremos más densidad de información (el filtro condensa 9 pixeles en 1 y en la siguiente capa cada uno de estos pixeles combinación de nueve, se volverán a agrupar en 1 tomando 9).

Además mediante la combinación de filtros simples, es posible llegar a patrones más complejos, al igual que la visión humana extrae de formas simples patrones más complejos mediante la combinación de los mismos. Debido a esto generalmente las redes convolucionales se representan como un embudo.




"Diagrama de una CNN meramente explicativo (Independiente del modelo ResNet50V2)"

Figura 4-3. Diagrama de una CNN meramente explicativo.

4.3. ResNet50V2

En el campo de la visión por computadora, ResNet50V2 es uno de los modelos más utilizados basados en la arquitectura de redes neuronales convolucionales. Es la segunda versión del modelo ResNet50, y a su vez es una versión reducida del modelo ResNetV2, el cual cuenta con 152 capas. Todos estos modelos, han sido entrenados mediante el data set ImageNet, que cuenta con 1000 clases diferentes y 1.281.167 imágenes de entrenamiento, 50.000 de validación y 100.000 de test.


Este modelo cuenta con 50 capas entre las cuales se encuentran capas convolucionales, capas de normalización y la función de activación que utilizan es la Unidad Rectificada Linear (ReLU).




"Diagrama del Modelo ResNetV2 (Versión de mayor tamaño pero estructura similar)"

Figura 4-4. Diagrama del Modelo ResNetV2

Además una parte esencial del modelo ResNet es la arquitectura de bloques residuales (Residual Net, de ahí su nombre), la cual implementa conexiones entre capas, llamadas skip connections. Estas conexiones permiten a las CNN mejorar su eficiencia, acelerando la búsqueda de los parámetros que ajustan la red.



"Skip connection identidad"



"Skip connection con capa convolucional"

Figura 4-5. Skip connection

4.4. Procesamiento Imágenes De Las Radiografías

Utilizando el modelo ResNet50V2 antes descrito hemos utilizado un data set compuesto por 5856 imágenes para reentrenar las últimas capas de tal manera que el modelo tan solo pueda clasificar las imágenes en dos categorías: “Pneumonía” o “Normal”. El esquema que ha sido seguido a la hora de entrenar el modelo es el siguiente.




Figura 4-6. Esquema de entrenamiento del modelo

Capítulo 5 - Resultados

5.1. Sin Preprocesamiento

La primera prueba ha sido realizada utilizando las imágenes originales sin aplicarles ninguna modificación. Únicamente hemos realizado un resize a 220x220 para cumplir con los estándares del modelo pre-entrenado utilizado. Además también hemos realizado una normalización de los valores de la imagen (entre 0 y 1) para mejorar el entrenamiento.

Se han obtenido las métricas que serán presentadas a continuación, utilizando un máximo de 50 épocas y creando un checkpoint cada 5 épocas.

En primer lugar observamos una buena métrica inicial con una precisión de un 88% en ambas categorías

	precision	recall	f1-score	support
0	0.88	0.88	0.88	8
1	0.88	0.88	0.88	8
accuracy			0.88	16
macro avg	0.88	0.88	0.88	16
weighted avg	0.88	0.88	0.88	16

Figura 5-1. Métricas

Más específicamente, en la validación se obtuvo que acierta el diagnóstico de 14 de cada 16 imágenes. En ambos casos, las imágenes etiquetadas como "Pneumonia" o "Normal" tuvieron un fallo por lo que no se aprecia ningún sesgo hacia un tipo en particular. Para comprender la siguiente figura se definirán los siguientes términos.

- FP: False Positive.
- TN: True Negative.
- TP: True Positive.
- FN: False Negative.

	Predicton	Truth	Results
0	0	0	TN
1	0	0	TN
2	0	0	TN
3	0	0	TN
4	0	0	TN
5	1	0	FP
6	0	0	TN
7	0	0	TN
8	1	1	TP
9	1	1	TP
10	1	1	TP
11	1	1	TP
12	0	1	FN
13	1	1	TP
14	1	1	TP
15	1	1	TP

Figura 5-2. Resultados de la evaluación de las imágenes

Para comprender mejor los errores del modelo, hemos separado por un lado el falso positivo

	Predicton	Truth	Results
5	1	0	FP

Figura 5-3. Resultados de los falsos positivos de las imágenes

Y también, el falso negativo

	Predicton	Truth	Results
12	0	1	FN

Figura 5-4. Resultados de los falsos positivos de las imágenes

Esto se puede observar más fácilmente en la Matriz de confusión generada:




Figura 5-5. Matriz de confusión

Para visualizar un ejemplo, el modelo ha catalogado la imagen que se muestra en la siguiente figura como un falso positivo, es decir, ha indicado que tenía neumonía cuando no era el caso.




Figura 5-6. Ejemplos falsos positivos

Por último, podemos comentar sobre el proceso de entrenamiento y validación de nuestro modelo.




Figura 5-7. Entrenamiento vs. Validación

Podemos observar en ambos casos unas métricas muy buenas desde el primer momento, pero, sin embargo, un estancamiento muy acelerado que concluyó en una finalización del entrenamiento muy temprana.

Pese a que la media de precisión de estas variables es bastante aceptable, hemos continuado realizando pruebas y ajustes con distintas modificaciones sobre las imágenes para aumentar la precisión.

5.2. Primer preprocesamiento

En la siguiente prueba realizada hemos aplicado un leve preprocesamiento, incluyendo el resize, blur y normalizado, a las imágenes.

Se puede observar que se han obtenido unas métricas prácticamente idénticas al primer entrenamiento.

	precision	recall	f1-score	support
0	0.88	0.88	0.88	8
1	0.88	0.88	0.88	8
accuracy			0.88	16
macro avg	0.88	0.88	0.88	16
weighted avg	0.88	0.88	0.88	16

Figura 5-8. Métricas

Por lo que podemos observar que esta primera aproximación no ha tenido un gran impacto en el modelo. Cometiendo, además, los mismos errores que su precedente.




Figura 5-9. Matriz de confusión

No obstante, encontramos una leve diferencia en el proceso de entrenamiento, sin estancamiento y con mayores bajadas del 'validation loss'.

Esto nos puede dar a entender que habría un mejor rendimiento con un proceso de entrenamiento más largo y con un conjunto de datos de validación más grande.




Figura 5-10. Entrenamiento vs. Validación

5.3. Preprocesamiento con aumento de datos

Para esta tercera prueba hemos utilizado las imágenes aplicando 'data augmentation'. Concretamente hemos aplicado un leve filtro de ruido gaussiano, además de otras modificaciones propias del ImageDataGenerator.

```
train_datagen = ImageDataGenerator(  
    rescale=1./255,  
    rotation_range=40,  
    width_shift_range=0.2,  
    height_shift_range=0.2,  
    zoom_range=0.2,  
    horizontal_flip=True,  
    fill_mode='nearest',  
    preprocessing_function=custom_augmentation  
)
```

Figura 5-11. Aumentos de datos

Como se puede observar, hemos realizado shifts de anchura y de altura, una leve rotación, un pequeño zoo, volteo horizontal y nuestro método de custom_augmentation donde aplicamos el ruido.

En primer lugar, observamos una mejora con respecto a los dos modelos anteriormente mencionados, alcanzando una precisión total de 94%.

	precision	recall	f1-score	support
0	1.00	0.88	0.93	8
1	0.89	1.00	0.94	8
accuracy			0.94	16
macro avg	0.94	0.94	0.94	16
weighted avg	0.94	0.94	0.94	16

Figura 5-12. Métricas

Los resultados obtenidos en la validación fueron de 15 aciertos de las 16 imágenes disponibles en este conjunto. Concretamente sólo se obtuvo un fallo de clasificación en las imágenes normales.

	Predicton	Truth	Results
0	0	0	TN
1	0	0	TN
2	0	0	TN
3	0	0	TN
4	0	0	TN
5	1	0	FP
6	0	0	TN
7	0	0	TN
8	1	1	TP
9	1	1	TP
10	1	1	TP
11	1	1	TP
12	1	1	TP
13	1	1	TP
14	1	1	TP
15	1	1	TP

Figura 5-13. Resultados de la evaluación de las imágenes

Para una mejor visualización, nuevamente mostramos la matriz de confusión resultante del nuevo modelo.




Figura 5-14. Matriz de confusión

A su vez, para visualizar un ejemplo, el modelo ha fallado catalogado la imagen que se muestra en la siguiente figura como un falso positivo. Vemos que se trata de la misma imagen que el caso de los dos modelos anteriores.




Figura 5-15. Ejemplos falsos positivos

La siguiente figura muestra el conjunto de 8 imágenes etiquetadas como normales. De esta manera, podemos comparar el falso positivo mostrado en la figura anterior con el resto de imágenes que fueron bien evaluadas.




Figura 5-16. Conjunto de imágenes 'normales'

Como primeras conclusiones a simple vista observamos que la parte inferior de la imagen es más voluminosa que en el resto de imágenes por lo que podría estar recogiendo esta característica como indicador de neumonía. Podríamos realizar pruebas aumentando el zoom para disminuir la importancia de esa zona para la toma de decisiones.

Por último, respecto a la validación y el entrenamiento, vemos una tendencia de disminución del 'validation loss' lo que ha permitido que no se estanque y que haya durado hasta 18 épocas.




Figura 5-17. Entrenamiento vs. Validación

De esta forma, podemos concluir no solo que este modelo ha obtenido las mejores métricas sino que ha tenido una mayor tasa de aprendizaje actualizando y cambiando pesos para no quedar estancado tan rápidamente como los primeros dos modelos.

5.4. Malos resultados

Cabe destacar que, durante el proceso de entrenamiento, se han probado distintas métricas y modificaciones como las comentadas a lo largo de esta memoria.

Por ello, tras probar y obtener los resultados, hemos comprobado que técnicas como el uso de un umbral o 'threshold' suponía un sesgo hacia los falsos positivos dándonos resultados como el siguiente.




Figura 5-18. Matriz de confusión

Donde se puede observar una clara tendencia a fallar en categorizar las imágenes normales correctamente.

Podemos deducir que el uso de esta técnica tan agresiva durante el entrenamiento, explica que a la hora de validar el modelo la mayoría de imágenes las clasifícase como neumonía.

	precision	recall	f1-score	support
0	1.00	0.38	0.55	8
1	0.62	1.00	0.76	8
accuracy			0.69	16
macro avg	0.81	0.69	0.65	16
weighted avg	0.81	0.69	0.65	16

Figura 5-19. Métricas

Se puede observar como crece el 'validation loss' durante el proceso de entrenamiento, por ello decidimos descartar esta característica al estar afectando de forma tan directa al modelo.




Figura 5-20. Entrenamiento vs. Validación

Capítulo 6 - Conclusiones y trabajo futuro

En conclusión, el desarrollo y aplicación de modelos de inteligencia artificial en la medicina, como el de este trabajo, tienen un potencial significativo para mejorar la precisión y eficiencia de los diagnósticos clínicos. A lo largo de este trabajo, hemos investigado las diferentes etapas del proceso de programación y entrenamiento.

Este trabajo nos ha brindado la oportunidad de tener una visión más detallada sobre el rendimiento de diferentes métodos de entrenamiento y preprocesamiento de imágenes.

Analizando los resultados, se ve que el modelo sin preprocesamiento, el modelo inicial, logró una precisión del 88% en ambas categorías. A pesar de que el rendimiento fuese bueno, realizar ajustes menores al código no ayudó destacablemente a este. El siguiente modelo, en el que se introduce el preprocesamiento, no mejoró significativamente el rendimiento aunque sí estabilizó el proceso de entrenamiento. Añadir técnicas de data augmentation llevó a una gran mejora en la precisión, llegando al 94%, disminuyendo el "validation loss" y estancándose menos. El uso de técnicas, como aplicar umbral o threshold, fueron contraproducentes ya que produjeron más falsos positivos.

Resumiendo, los resultados indican que un enfoque con más preprocesamiento, como data augmentation, junto con la exclusión de técnicas que puedan llegar a introducir sesgos, puede mejorar el rendimiento del modelo en este caso.

En relación al trabajo futuro sobre este modelo, cabe destacar que se podría probar con más data augmentation y el entrenamiento del modelo añadiendo más épocas y una mayor cantidad de imágenes. Además, se podría analizar el falso positivo que ha fallado en el modelo final para, así, observar las características que llevan a que el modelo se equivoque.

Finalmente, se podría desarrollar un apartado visual para que el programa fuese funcional para un usuario externo a este proyecto.

Estas conclusiones proporcionan una base sólida para futuras investigaciones y esperamos que sea de ayuda en la detección de enfermedades mediante el análisis de imágenes médicas.

BIBLIOGRAFÍA

Lucas, A., & Gil-Delgado, M. (n.d.). Trabajo Fin de Grado Redes neuronales aplicadas a la generación de imágenes.

https://oa.upm.es/75103/1/TFG_LUCAS_MARTIN_GIL_DELGADO.pdf

Pérez Ortiz De Landaluze, M., & Mellado, S. (n.d.). Equation Chapter 1 Section 1.

<https://biblus.us.es/bibing/proyectos/abreproy/93772/fichero/TFG-3772+P%C3%89REZ+ORTIZ+DE+LANDALUCE%2C+MARTA.pdf>

Inteligencia Artificial en la Medicina | IBM. (n.d.). [Www.ibm.com](http://www.ibm.com).
<https://www.ibm.com/es-es/topics/artificial-intelligence-medicine>

luciaclemares. (2023, September 11). ¿Qué aplicaciones tiene la Inteligencia Artificial? Telefónica.
<https://www.telefonica.com/es/sala-comunicacion/blog/aplicaciones-tiene-inteligencia-artificial/>

Rouhiainen, L. (2018). Inteligencia artificial. Madrid: Alienta Editorial, 20-21.

Expósito Gallardo, María del Carmen, and Rafael Ávila Ávila. "Aplicaciones de la inteligencia artificial en la Medicina: perspectivas y problemas." *Acimed* 17.5 (2008): 0-0.

GALIPIENSO, A., ISABEL, M., CAZORLA QUEVEDO, M. A., Colomina Pardo, O., Escolano Ruiz, F., & LOZANO ORTEGA, M. A. (2003). Inteligencia artificial: modelos, técnicas y áreas de aplicación. Ediciones Paraninfo, SA.

covid

Abreu, Manuel Ramón Pérez, Jairo Jesús Gomez Tejeda, and Ronny Alejandro Dieguez Guach. "Características clínico-epidemiológicas de la COVID-19." *Revista Habanera de Ciencias Médicas* 19.2 (2020): 1-15.

Molina-Molina, María. "Secuelas y consecuencias de la COVID-19." *Medicina respiratoria* 13.2 (2020): 71-77.

Pérez, Luis C. Velázquez. "La COVID-19: reto para la ciencia mundial." *Anales de la Academia de Ciencias de Cuba* 10.2 (2020): 763.

Dzieciatkowski, Tomasz, et al. "COVID-19 challenge for modern medicine." *Cardiology journal* 27.2 (2020): 175-183.

Hindarto, D. (2023). Use ResNet50V2 Deep Learning Model to Classify Five Animal Species. *Jurnal JTIK (Jurnal Teknologi Informasi Dan Komunikasi)*, 7(4), 758–768.

Haruna, U., Ali, R., & Man, M. (2023). A new modification CNN using VGG19 and ResNet50V2 for classification of COVID-19 from X-ray radiograph images. *Indonesian Journal of Electrical Engineering and Computer Science*, 31(1), 369-377.

O'Shea, K., & Nash, R. (2015, 26 noviembre). An Introduction to Convolutional Neural Networks. *arXiv.org*. <https://arxiv.org/abs/1511.08458>

APÉNDICES

ANEXO - Tareas realizadas por miembro

A continuación, se detalla la participación de cada miembro del grupo en este proyecto.

Miembro	Tareas
Andrés Viñé Sánchez	- Capítulo 4 de la memoria - Revisión de la memoria - Pruebas con el entrenamiento del modelo
Beatriz Aedo Díaz	- Pruebas con el entrenamiento del modelo. - Capítulos 2, 3, 5, 6 y bibliografía de la memoria. - Revisión y corrección de errores en la memoria.
Candela Esquinas Sánchez	- Pruebas con el entrenamiento del modelo. - Capítulo 1 y resumen de la memoria.
José Antonio Ruiz Heredia	- Pruebas con el preprocesado de las imágenes. - Pruebas con el entrenamiento del modelo. - Métricas de los distintos modelos. - Capítulo 5 de la memoria.

Tabla 1. Trabajo realizado por cada miembro